

Projekt Etap 4 — Analiza pogody i generowanie opisów pogodowych

PDW: Zastosowania języka Python w Data Science i Artificial Intelligence

Grupa 9:

Majewski Aleksander – 73037

Palade Mikołaj – 51204

Ryczywolski Jakub – 73184

Szatyłowicz Adam – 72327

Uzar Maciej – 71594

1. Wprowadzenie i cel projektu

Projekt dotyczy pobierania danych pogodowych dla wybranych miast w Polsce, analizy zależności pomiędzy parametrami pogodowymi oraz wykorzystania modelu językowego do generowania krótkich opisów pogody w języku polskim. Stanowi on kontynuację wcześniejszych etapów: pobierania danych z OpenWeather API i analizy korelacji (etap 2) oraz wyboru modelu Transformer (etap 3).

Główna funkcjonalność części programistycznej obejmuje pobranie danych z OpenWeather API, zapis do pliku CSV, obliczenie korelacji Pearsona i wygenerowanie mapy cieplnej korelacji. W części LLM wybrano model allegro/plt5-small, którego zadaniem jest przekształcenie ustrukturyzowanych danych liczbowych w krótki raport pogodowy w języku naturalnym. W etapie 4 część badawcza została domknięta: przeprowadzono realny fine-tuning, obliczono metryki BLEU i ROUGE oraz zapisano przykłady generacji modelu.

2. Struktura oddawanej paczki

Paczka jest zgodna z instrukcją wysyłania projektu na Plato. Pliki wirtualnego środowiska oraz katalog repozytorium nie są wysyłane (wykluczone w .gitignore).

```
P4_9_Analiza-Pogody-Polska_73184/  
  README.txt  
  main.py  
  raport.pdf  
  requirements.txt  
  .env.example  
  src/  
    fetch_weather.py  
    analiza.py  
    llm_finetuning.py  
    notebook_analiza.ipynb  
    notebook_finetuningNaColabie.ipynb  
  data/  
    pogoda_polska.csv  
    llm_dataset.csv  
  outputs/  
    AnalizaZdjecie.png  
    macierz_korelacji.csv  
    llm_eval.json
```

3. Źródło i opis danych

Źródłem danych jest OpenWeather API. Skrypt src/fetch_weather.py pobiera aktualne informacje pogodowe dla listy 50 polskich miast. Do paczki dołączono odtwarzalny plik data/pogoda_polska.csv (50 wierszy). Wszystkie rekordy pochodzą z jednego snapshotu czasowego: 2026-01-01T10:00:00+00:00. Ponieważ dane pogodowe są dynamiczne, ponowne pobranie z API może dać inne wartości; interpretacja w raporcie opiera się na dołączonym pliku CSV.

Kolumna	Znaczenie
Miasto	Nazwa miasta w Polsce
Temperatura	Temperatura powietrza w stopniach Celsjusza

Temp_Odczuwalna	Temperatura odczuwalna w stopniach Celsjusza
Cisnienie	Ciśnienie atmosferyczne w hPa
Wilgotnosc	Wilgotność powietrza w procentach
Predkosc_Wiatru	Prędkość wiatru w m/s
Zachmurzenie	Zachmurzenie w procentach
Opis	Tekstowy opis pogody zwrócony przez API

4. Implementacja kodu

4.1. Pobieranie danych

Za pobieranie odpowiada `src/fetch_weather.py`. Klucz API nie jest zapisany w kodzie — program korzysta ze zmiennej środowiskowej `OWM_API_KEY` lub lokalnego pliku `.env` (niewysyłanego na Plato).

4.2. Analiza korelacji

Za analizę odpowiada `src/analiza.py`: wczytuje `data/pogoda_polska.csv`, oblicza macierz korelacji Pearsona, zapisuje `outputs/macierz_korelacji.csv` i generuje mapę cieplną `outputs/AnalizaZdjecie.png`.

4.3. Część LLM i ewaluacja

Za część LLM odpowiada `src/llm_finetuning.py`: budowa par `input_text` → `target_text`, fine-tuning `allegro/plt5-small` oraz obliczenie metryk BLEU (`sacrebleu`) i ROUGE-1/2/L (`rouge_score`). Wynik, metryki i przykłady generacji zapisywane są do `outputs/llm_eval.json`. Notebook `src/notebook_finetuningNaColabie.ipynb` odtwarza cały proces na Google Colab z GPU.

4.4. Uruchomienie

```
pip install -r requirements.txt
python main.py --mode analyze
python main.py --mode all
python main.py --mode llm-dataset
python src/llm_finetuning.py --train --epochs 50 --lr 3e-4
```

5. Analiza korelacji Pearsona — wyniki

W finalnej paczce pozostawiono jeden, spójny zestaw odtwarzalnych danych i wyników: `data/pogoda_polska.csv`, `outputs/macierz_korelacji.csv` oraz `outputs/AnalizaZdjecie.png`. Poniższe wartości pochodzą bezpośrednio z dołączonego CSV.


Hipot eza	Wynik z CSV	Interpretacja
H1	Wiatr – temp. odczuwalna: -0.27	Zależność ujemna, ale słaba. Hipoteza o silnej korelacji ujemnej nie potwierdzona.

H2	Wiatr: -0.27; wilgotność: -0.43	Wilgotność ma większą wartość bezwzględną korelacji niż wiatr. Hipoteza nie potwierdzona.
H3	Zachmurzenie - temp.: -0.04	Korelacja bliska zeru. Brak istotnej zależności liniowej.

Najsilniejsza dodatnia zależność występuje między temperaturą rzeczywistą i odczuwalną (0.90). Najważniejsza zależność ujemna dla temperatury odczuwalnej dotyczy wilgotności (-0.43), a nie wiatru.

6. Wynik graficzny analizy

Rysunek 1 jest dokładnie plikiem generowanym przez kod (outputs/AnalizaZdjecie.png), dzięki czemu raport, macierz CSV i wykres są spójne.



Rys. 1. Mapa cieplna korelacji Pearsona dla parametrów pogodowych.

7. Model LLM

Wybrano model allegro/plt5-small — Transformer typu Encoder-Decoder przeznaczony do zadań text-to-text. Model otrzymuje dane pogodowe zapisane jako tekst strukturalny i generuje krótki opis pogody po polsku. Wybór uzasadniono w etapie 3 natywną obsługą języka polskiego oraz niskimi wymaganiami sprzętowymi wariantu „small” (mieści się na GPU T4 w Google Colab).

Przykładowe wejście:

wygeneruj raport pogody: miasto Warszawa; temperatura 8.0 C; temperatura odczuwalna 3.2 C; ciśnienie 1015 hPa; wilgotnosc 65 procent; wiatr 4.3 m/s; zachmurzenie 93 procent

Oczekiwane wyjście:

W mieście Warszawa temperatura wynosi 8.0 stopni C, a temperatura odczuwalna 3.2 stopni C. Ciśnienie wynosi 1015 hPa, wilgotność 65%, prędkość wiatru 4.3 m/s, a zachmurzenie 93%. Opis pogody : duże zachmurzenie.

Na podstawie CSV przygotowano data/llm_dataset.csv (50 par input_text → target_text).

8. Fine-tuning modelu — przebieg i wyniki

8.1. Konfiguracja treningu

Fine-tuning przeprowadzono w Google Colab z GPU (T4) przy użyciu biblioteki transformers (Seq2SeqTrainer). Zbiór 50 przykładów podzielono na treningowy i ewaluacyjny w proporcji 80/20 (random_state=42).

Parametr	Wartość
Model bazowy	allegro/plt5-small
Liczba przykładów	50 (40 treningowych / 10 ewaluacyjnych)
Liczba epok	50
Learning rate	3e-4
Batch size	4
Warmup ratio / weight decay	0.1 / 0.01
Generacja	beam search (num_beams=4), no_repeat_ngram_size=3
Metryki	eval_loss, BLEU (sacrebleu), ROUGE-1/2/L (rouge_score)

8.2. Wpływ hiperparametrów (obserwacja metodologiczna)

Pierwsze przebiegi treningu nie powiodły się i dobrze ilustrują wrażliwość modeli typu mT5 na hiperparametry. Przy domyślnym learning rate 5e-5 model był silnie niedouczony: po 3 epokach eval_loss wynosił ok. 7.36, a po 15 epokach ok. 4.94, przy BLEU bliskim zera (0.33) i generacjach degeneracyjnych (powtórzenia fraz, błędne tokeny). Dopiero podniesienie learning rate do 3e-4, dodanie rozgrzewki (warmup) i zwiększenie liczby epok do 50 pozwoliło modelowi nauczyć się szablonu opisu pogody.

8.3. Wyniki końcowe

Wartości pochodzą bezpośrednio z pliku outputs/llm_eval.json.

Metryka	Wartość	Interpretacja
eval_loss	0.0161	Bardzo niska strata — model dobrze dopasował się do danych.
BLEU	97.55	Bardzo wysoka zgodność n-gramów z tekstem oczekiwanym.
ROUGE-1	98.45	Niemal pełne pokrycie pojedynczych słów.
ROUGE-2	98.41	Wysokie pokrycie par słów (bigramów).
ROUGE-L	98.45	Wysoka zgodność najdłuższej wspólnej sekwencji.

8.4. Przykłady generacji

Przykład poprawny (Radom):

MODEL: W mieście Radom temperatura wynosi 6.4 stopni C, a temperatura odczuwalna 3.7 stopni C. Ciśnienie wynosi 1020 hPa, wilgotność 60%, prędkość wiatru 1.3 m/s, a zachmurzenie 63%. Opis pogody: pochmurnie.

Generacja jest identyczna z tekstem oczekiwanym — model poprawnie podstawiał wszystkie wartości liczbowe i zachował strukturę zdania.

Przykład z błędem (Grudziądz):

MODEL: W mieście Grudziądz temperatura wynosi 14.6 stopni C, a temperatura odczuwalna 1018 hPa, wilgotność 35%, prędkość wiatru 5.5 m/s, a zachmurzenie 59%. Opis pogody: pochmurnie.

Model pominął fragment „10.6 stopni C. Ciśnienie wynosi” i wstawił wartość ciśnienia w miejsce temperatury odczuwalnej. To przykład halucynacji/przeskoczenia pola, potwierdzający ograniczenie wynikające z małego, jednoczasowego zbioru danych — zgodnie z ryzykiem wskazanym w etapie 3.

8.5. Status części LLM

Element	Status w paczce
Model bazowy	allegro/plt5-small
Dataset	data/llm_dataset.csv, 50 przykładów
Kod treningu i ewaluacji	src/llm_finetuning.py (BLEU/ROUGE)
Metryki	outputs/llm_eval.json: eval_loss 0.0161, BLEU 97.55, ROUGE-L 98.45
Wagi modelu	outputs/plt5-weather/ — udostępnione przez Google Drive (link w README)
Najważniejsze ryzyko	mały, jednoczasowy snapshot; overfitting i możliwe halucynacje liczb

9. Zasoby, ograniczenia i informacja o użyciu AI

Zasoby: trening wykonano na bezpłatnym GPU T4 w Google Colab; czas uczenia rzędu kilkunastu minut. Ograniczenia: zbiór liczy tylko 50 przykładów z jednego snapshotu czasowego, co rodzi ryzyko przeuczenia i halucynacji wartości liczbowych.

Użycie AI w projekcie ma dwie role. Po pierwsze, model allegro/plt5-small jest elementem badawczym i generuje opisy pogody na podstawie danych liczbowych. Po drugie, narzędzia AI (ChatGPT oraz Claude) zostały użyte pomocniczo do uporządkowania raportu, README i struktury katalogu, usunięcia klucza API z kodu, przygotowania kodu ewaluacji (BLEU/ROUGE) oraz doboru hiperparametrów. Wszystkie wartości liczbowe pochodzą z faktycznie uruchomionego kodu.

10. Wnioski

Projekt pokazuje pełny przepływ pracy: od pobrania danych z API, przez analizę statystyczną, po fine-tuning modelu LLM generującego opisy w języku naturalnym. Raport, macierz korelacji CSV i wykres są spójne, bo wszystkie wartości pochodzą z tego samego pliku data/pogoda_polska.csv.

Na odtwarzalnym snapshocie korelacja wiatr – temperatura odczuwalna wynosi -0.27, więc nie potwierdza silnej zależności ujemnej. Wilgotność jest silniej powiązana z temperaturą odczuwalną (-0.43), a zachmurzenie i temperatura mają korelację bliską zeru (-0.04).

Część LLM została domknięta: po dostrojeniu hiperparametrów (learning rate $3e-4$, 50 epok) model osiągnął bardzo wysokie metryki (BLEU 97.55, ROUGE-L 98.45, eval_loss 0.0161) i generuje poprawne opisy. Należy jednak podkreślić, że tak wysokie wartości wynikają w dużej mierze z silnie szablonowej struktury danych — zadanie sprowadza się do podstawienia liczb do stałego wzorca, więc metryki mierzą raczej odtworzenie szablonu niż zdolność generalizacji. Pojedyncze błędy (przykład Grudziądza) pokazują, że model może mylić pola liczbowe. Rzetelna ocena generalizacji wymagałaby danych z wielu snapshotów czasowych oraz zróżnicowania sposobu formułowania opisów.

11. Źródła i materiały

- OpenWeather API — źródło danych pogodowych.
- Raport etapu 2 — analiza korelacji Pearsona dla miast w Polsce.
- Raport etapu 3 — wybór i implementacja modelu Transformer (allegro/plt5-small).
- Hugging Face Transformers, sacrebleu, rouge_score — biblioteki fine-tuningu i ewaluacji.
- Repozytorium: https://github.com/xM4ngy/P4_9_Analiza-Pogody-Polska